

Arquitetura Cloud – Estratégia Multi-Cloud

MBA Data Science & Advanced Analytics | Cloud Computing for Data Science | Turma: DSA_32 | RA: 2600190 | Lilian Reis

1. Objetivo

Entregar um trabalho no formato de um documento, apresentando todos os conhecimentos adquiridos, contendo o planejamento de uma estratégia multi-cloud eficiente e performática, considerando os provedores AWS, Azure, GCP e ambientes on-premises.

É essencial seguir um passo-a-passo estruturado e considerando os temas a seguir:

- CapEx, OpEx, ROI e TCO;
- Interoperabilidade de Dados;
- Convergência entre Ambientes;
- Segurança;
- Ganho Técnico e Operacional.

2. Cenário de Negócio

O setor de seguros é altamente competitivo e orientado por dados, exigindo agilidade na análise de informações, precisão na precificação de produtos e eficiência na gestão de sinistros. As seguradoras lidam com grandes volumes de dados estruturados e não estruturados, provenientes de sistemas transacionais legados (on-premises), canais digitais, parceiros externos e dispositivos IoT. Além disso, o negócio demanda:

- Alta disponibilidade dos sistemas críticos;
- Capacidade de escalar rapidamente análises e modelos de Machine Learning;
- Redução de custos operacionais;
- Segurança e conformidade regulatória;
- Integração entre áreas técnicas e de negócio.

Nesse contexto, a adoção de uma estratégia multi-cloud híbrida torna-se fundamental para atender às necessidades do negócio, permitindo o uso das melhores capacidades de cada provedor de nuvem, ao mesmo tempo em que reduz dependência de um único fornecedor (vendor lock-in).

3. Arquitetura Multi-Cloud

A arquitetura proposta considera um ambiente híbrido e multi-cloud, integrando on-premises com os provedores AWS, Azure e GCP, cada um com responsabilidades bem definidas, de acordo com suas especializações.

A estratégia adotada não consiste na replicação integral de sistemas entre as nuvens, mas na distribuição estratégica de **camadas da arquitetura**, maximizando desempenho, eficiência operacional e governança.

Papéis dos Ambientes e Camadas na Arquitetura:

1. Ingestão de Dados: Ambiente On-Premises

Responsável pelos sistemas transacionais legados da seguradora, como core de apólices, faturamento e cadastro de clientes. Esses sistemas continuam operando localmente, garantindo estabilidade e aderência a requisitos regulatórios, com integração segura às nuvens públicas.

2. Camada de Armazenamento: AWS (Data Lake)

A AWS é utilizada como repositório central de dados, hospedando o Data Lake corporativo. Nesse ambiente são armazenados os dados brutos, históricos e dados tratados, organizados em camadas (bronze, silver e gold), servindo como fonte única de verdade (Single Source of Truth) para toda a organização.

3. Camada de Processamento: GCP/Databricks (Analytics e Machine Learning)

A GCP hospeda o ambiente de processamento analítico e Machine Learning por meio do Databricks. Essa camada é responsável pela engenharia de dados, treinamento de modelos preditivos, análises avançadas e uso de APIs especializadas de Inteligência Artificial para enriquecimento dos dados, como processamento de documentos e imagens relacionados a sinistros.

4. Camada de Visualização: Azure (Consumo e Governança Corporativa)

A Azure é utilizada como camada de consumo de dados e governança, integrando identidade corporativa, controle de acesso e ferramentas de Business Intelligence. O uso do Power BI possibilita que as áreas de negócio consumam informações analíticas de forma intuitiva e segura, apoiando a tomada de decisão.

A arquitetura multi-cloud proposta proporciona os seguintes benefícios ao negócio:

- Flexibilidade para utilizar serviços especializados de cada provedor;
- Maior resiliência e redução de riscos operacionais;
- Melhor aproveitamento de investimentos em tecnologia;
- Integração eficiente entre ambientes on-premises e nuvens públicas;
- Base sólida para iniciativas avançadas de analytics e Machine Learning.

Resumo da Arquitetura:

Bloco	Camada	Cloud	Ferramenta	Descrição
Ingestão de Dados	Ingestão de Dados	On-Premises / AWS	Sistemas Legados / AWS Glue / Amazon Kinesis	Os sistemas transacionais on-premises geram dados de apólices, clientes e sinistros. A captura desses dados ocorre de forma híbrida, utilizando o AWS Glue para cargas em lote (batch) e o Amazon Kinesis para ingestão em tempo real (streaming), garantindo baixa latência, escalabilidade e suporte a fluxos contínuos de dados.
Armazenamento	Data Lake	AWS	Amazon S3 + Delta Lake	O Amazon S3 hospeda o Data Lake corporativo, armazenando dados estruturados, semiestruturados e não estruturados. O uso do Delta Lake garante transações ACID, versionamento e auditoria dos dados.
Processamento / Machine Learning	Engenharia de Dados	GCP	Databricks (Spark)	Responsável pelo processamento distribuído, transformação de dados e implementação da Arquitetura Medalhão (bronze, silver e gold), suportando múltiplas áreas do negócio.

	Modelagem e MLOps	GCP	Databricks + MLflow	Ambiente para treinamento, versionamento e gestão do ciclo de vida de modelos de Machine Learning, como score de risco e detecção de fraudes.
Governança de Dados	Metadados e Linhagem	Databricks (GCP) / Multi-Cloud	Databricks Unity Catalog	Controle centralizado de metadados, permissões, linhagem e auditoria de dados, garantindo governança portátil e aderente a ambientes híbridos e multi-cloud.
Segurança	Identidade e Acesso	Azure	Azure AD	Gestão centralizada de identidades e autenticação, permitindo controle unificado de acesso aos dados e ferramentas analíticas em múltiplas nuvens.
	Criptografia e Proteção	AWS / Multi-Cloud	AWS KMS / IAM	Criptografia de dados em repouso e em trânsito, além de controle granular de permissões, garantindo conformidade com LGPD e proteção de dados sensíveis.
Visualização	Analytics e BI	Azure	Power BI	Camada de visualização e consumo analítico utilizada pelas áreas de negócio, permitindo dashboards interativos, relatórios executivos e suporte à tomada de decisão.

4. Análise Financeira e de Custos (CapEx, OpEx, ROI e TCO)

- **Capex - Capital Expenditure (Investimento de Capital):** a adoção da arquitetura híbrida e multi-cloud reduz significativamente os investimentos iniciais em infraestrutura, substituindo a aquisição de hardware e licenças por serviços sob demanda. O ambiente on-premises permanece apenas para sistemas legados críticos, evitando novos investimentos imediatos.
- **OpEx - Operational Expenditure (Custo Operacional):** os custos passam a ser predominantemente operacionais, baseados no uso efetivo dos recursos em nuvem. O modelo multi-cloud permite maior controle financeiro, escalabilidade conforme a demanda e redução de desperdícios, por meio da utilização de serviços gerenciados.
- **ROI - Return on Investment (Retorno sobre o Investimento):** o retorno sobre o investimento é obtido principalmente por ganhos operacionais, como maior agilidade analítica, automação de processos, melhoria na precisão de modelos de Machine Learning e maior produtividade das equipes, impactando positivamente a eficiência do negócio.
- **TCO - Total Cost of Ownership (Custo Total de Propriedade):** o custo total de propriedade é otimizado ao longo do tempo pela redução de custos de manutenção, uso de serviços gerenciados, centralização do Data Lake, portabilidade entre provedores e governança unificada, resultando em uma solução mais eficiente e sustentável.

Estima-se que a eliminação gradual de data centers locais reduza o CapEx em aproximadamente 40% nos primeiros dois anos, enquanto o modelo de pagamento por uso (OpEx) permite ajustar custos à demanda, evitando desperdícios. O ROI é acelerado pela redução do tempo de mercado de novos modelos de score de risco (de meses para semanas) e pela automação de processos de detecção de fraudes. O TCO é otimizado pelo uso de serviços gerenciados (menos overhead de manutenção) e pela portabilidade entre nuvens, que evita renegociações caras com fornecedores.

5. Interoperabilidade de Dados

A interoperabilidade de dados é um dos pilares da estratégia multi-cloud proposta, permitindo que diferentes áreas da organização, como TI, Analytics, Ciência de dados e Negócios, trabalhem de forma integrada a partir das mesmas fontes de dados corporativos.

Na arquitetura definida, os dados são gerados nos sistemas on-premises e incorporados ao ambiente de nuvem por meio de processos de ingestão em batch e streaming, utilizando ferramentas como **AWS Glue** e **Amazon Kinesis**. Após a ingestão, os dados são armazenados de forma centralizada no Data Lake corporativo, garantindo consistência e padronização das informações. O processamento analítico e as transformações de dados são realizados em uma camada desacoplada, utilizando o **Databricks**, permitindo que os mesmos conjuntos de dados sejam utilizados tanto para análises exploratórias quanto para modelos de Machine Learning. Já o consumo das informações ocorre por meio de ferramentas de Business Intelligence, como o **Power BI**, possibilitando que as áreas de negócio acessem os dados de forma segura e intuitiva.

A adoção de formatos abertos, camadas padronizadas de dados e ferramentas compatíveis com múltiplos provedores permite que os dados sejam processados e consumidos em diferentes ambientes de nuvem, como **AWS**, **GCP** e **Azure**, reduzindo dependência de soluções proprietárias, evitando redundâncias e favorecendo a portabilidade e a escalabilidade do ambiente analítico.

A interoperabilidade é viabilizada pelo uso do Databricks como camada unificada de processamento, que lê diretamente os dados do S3 (AWS) por meio do protocolo S3A, aplica transformações e escreve os resultados de volta no S3 (camadas silver/gold). O Power BI, hospedado no Azure, conecta-se ao Databricks via JDBC/ODBC ou diretamente ao S3 por meio do conector nativo do Power BI para Amazon Athena ou usando o Databricks SQL Warehouse, garantindo baixa latência e governança centralizada.

6. Convergência entre Ambientes

A convergência entre ambientes é alcançada por meio da integração estruturada entre o ambiente on-premises e as nuvens públicas, formando uma arquitetura híbrida e multi-cloud coesa e bem governada.

Embora cada provedor desempenhe um papel específico dentro da arquitetura, todos os ambientes operam de forma integrada, garantindo fluxo contínuo de informações, governança centralizada e consistência dos dados. O uso do **Databricks** como plataforma de processamento analítico e Machine Learning contribui diretamente para essa convergência, uma vez que a ferramenta é baseada em tecnologias abertas e está disponível em múltiplos provedores de nuvem.

Essa característica permite que regras de negócio, pipelines de dados e modelos de Machine Learning possam ser migrados ou replicados entre diferentes ambientes de nuvem com baixo esforço, reduzindo dependência de fornecedor e facilitando a evolução da arquitetura ao longo do tempo.

Como resultado, a organização obtém maior flexibilidade tecnológica, continuidade operacional e capacidade de adaptação às demandas do negócio, sem comprometer desempenho, segurança ou governança.

A convergência entre ambientes também é reforçada pelo uso do **Unity Catalog**, que centraliza a governança de dados, metadados e acessos de forma unificada. Essa abordagem permite que diferentes áreas da organização compartilhem e utilizem as mesmas fontes de dados e ativos analíticos, independentemente do ambiente de nuvem, promovendo padronização, rastreabilidade e colaboração entre equipes técnicas e de negócio.

Além disso, o Unity Catalog facilita a portabilidade de dados e ativos analíticos entre provedores de nuvem, apoiando a estratégia multi-cloud ao reduzir acoplamento tecnológico e simplificar a gestão do ambiente analítico.

A integração on-premises com as nuvens é feita via AWS Glue (para batches) e Kinesis (para streaming), garantindo que dados de sistemas legados cheguem ao Data Lake de forma contínua. A autenticação federada com Azure AD permite que usuários on-premises acessem recursos no AWS e GCP usando as mesmas credenciais corporativas, simplificando o gerenciamento de identidades.

7. Segurança

A segurança da arquitetura multi-cloud proposta é baseada em controles centralizados de identidade, criptografia de dados e monitoramento contínuo, garantindo confidencialidade, integridade e disponibilidade das informações em todos os ambientes.

O controle de acesso aos recursos é realizado por meio de soluções de **Identity and Access Management (IAM)**, permitindo a definição de políticas baseadas em perfis, funções e princípio do menor privilégio. A integração com o **Active Directory (AD)** possibilita o uso de identidades corporativas centralizadas, facilitando a autenticação de usuários e o controle de acessos entre on-premises e nuvens públicas.

A proteção dos dados sensíveis é reforçada pelo uso de serviços de gerenciamento de chaves (**Key Management Service - KMS**), responsáveis pela criptografia de dados em repouso e em trânsito. Esses mecanismos garantem que informações críticas, como dados de clientes, apólices e sinistros, permaneçam protegidas ao longo de todo o ciclo de vida dos dados.

Cada provedor de nuvem (**AWS, Azure e GCP**) oferece serviços nativos de segurança que permitem auditoria, rastreabilidade de acessos e detecção de ameaças, assegurando conformidade com os requisitos regulatórios do setor de seguros.

A abordagem integrada reduz riscos operacionais, fortalece a postura de segurança da organização e viabiliza a adoção do modelo multi-cloud de forma controlada e confiável.

Esses mecanismos garantem conformidade com a LGPD, assegurando que dados sensíveis de clientes, como informações de apólices e sinistros, sejam tratados com os devidos controles de privacidade e proteção.

8. Ganho Técnico e Operacional

A adoção da arquitetura híbrida e multi-cloud proposta proporciona ganhos técnicos e operacionais significativos para a organização, alinhando tecnologia às necessidades do negócio de forma eficiente e sustentável.

Do ponto de vista técnico, a arquitetura permite maior escalabilidade, flexibilidade e desempenho no processamento de dados e modelos de Machine Learning. O uso do Data Lake corporativo possibilita armazenar, processar e consultar diferentes tipos de dados (estruturados, semiestruturados e não estruturados) provenientes de múltiplas fontes. A separação clara entre ingestão, armazenamento, processamento e consumo permite a evolução independente de cada camada, reduzindo impactos em sistemas legados e facilitando a incorporação de novas tecnologias. Além disso, o uso de plataformas portáteis e padrões abertos reduz o risco de dependência de fornecedor e aumenta a resiliência do ambiente.

Sob a perspectiva operacional, a centralização dos dados e a padronização dos processos permitem que diferentes áreas da organização trabalhem de forma integrada, utilizando as mesmas fontes de

informação. Isso resulta em maior agilidade na tomada de decisão, aumento da produtividade das equipes, redução de retrabalho e melhor governança dos dados corporativos.

Como resultado, a estratégia multi-cloud adotada não apenas suporta as demandas atuais da seguradora, mas também estabelece uma base sólida para a expansão de iniciativas avançadas de analytics, inteligência artificial e inovação, garantindo vantagem competitiva e sustentabilidade tecnológica no longo prazo.