

Projeto de Arquitetura Cloud: Data Lakehouse Seguradora - Score de Risco e BI

MBA Data Science & Advanced Analytics | Cloud Computing for Data Science | Turma: DSA_32 | RA: 2600190 | Lilian Reis

Sumário

1. Objetivo	[pág. 2]
2. Cenário de Negócio: Setor de Seguros	[pág. 2]
3. Arquitetura Nativa AWS vs. Arquitetura Proposta	[pág. 3]
4. Diagrama da Arquitetura.....	[pág. 4]
4.1 Resumo da Arquitetura.....	[pág. 5]
5. Conclusão	[pág. 5]

1. Objetivo

Desenvolver um processo de serviço gerenciado em nuvem que seja agnóstico ao provedor, que possa ser implementado em qualquer ambiente de nuvem (AWS, Azure, GCP). O trabalho deve contemplar todas as quatro etapas fundamentais de uma arquitetura de dados moderna: Ingestão de Dados, Armazenamento, Processamento, Visualização. Para cada etapa, o(a) aluno(a) deverá: Selecionar o provedor de nuvem de sua preferência. Identificar e utilizar ferramentas específicas desse provedor compatíveis com a etapa em questão. Justificar a escolha de cada ferramenta, apresentando o racional técnico e estratégico de sua adoção, considerando fatores como escalabilidade, custo, integração, e facilidade de uso.

Este exercício visa promover a compreensão prática da arquitetura orientada a serviços em nuvem, além de desenvolver a habilidade de desenhar soluções reutilizáveis e portáteis entre provedores diferentes.

2. Cenário de Negócio: Setor de Seguros

O mercado de seguros moderno exige rapidez na análise de dados para manter a competitividade. O cenário deste projeto foca no conceito de data-driven, baseado em três necessidades principais:

- **Personalização (Score de Risco):** Possibilidade de substituir ou aprimorar análises genéricas por modelos preditivos que calculam o risco individual em tempo real.
- **Redução de Fraudes:** Integrar múltiplas fontes de dados para identificar padrões atípicos e mitigar prejuízos financeiros.
- **Agilidade e Custo:** Possibilidade de migrar de uma infraestrutura rígida para a nuvem, permitindo escalabilidade imediata e redução de custos fixos (CapEx) para variáveis (OpEx).


Para viabilizar essas necessidades, a arquitetura adotada baseia-se no conceito de **Data Lakehouse**. Esta abordagem é fundamental para o setor de seguros, pois permite o processamento unificado de diversos tipos de dados em uma única plataforma: **Estruturados:** dados cadastrais de clientes e histórico de apólices (provenientes de bancos de dados relacionais). **Semiestruturados:** logs de aplicativos e arquivos JSON de telemetria veicular para análise de perfil de direção. **Não Estruturados:** Fotos de vistorias de sinistros, vídeos de câmeras de segurança e documentos PDF digitalizados.

A escolha pelo Lakehouse garante que a seguradora tenha a flexibilidade de um *Data Lake* para armazenar diversos tipos de arquivos e arquivos pesados (fotos/vídeos), com a performance e governança de um *Data Warehouse* para os cálculos de Score de Risco, análises e BI.

3. Arquitetura Nativa AWS vs. Arquitetura Proposta: AWS (Lakehouse + Databricks)

Bloco	Ferramenta Nativa AWS vs. Proposta	Descrição das Ferramentas	Justificativa da Escolha
Ingestão	AWS Glue / Amazon Kinesis	O Glue é focado em lotes (batch), enquanto o Kinesis processa melhor fluxos contínuos de dados (streaming) em tempo real.	O Kinesis foi escolhido pela baixa latência, permitindo que o Score de Risco e outras análises sejam calculados em tempo real com a interação com as aplicações.
Armazenamento	S3 (Parquet) vs. S3 (Delta Lake)	O Parquet é um formato de arquivo estático. O Delta Lake adiciona uma camada de gerenciamento que permite transações ACID e controle de versão.	O Delta Lake garante a integridade dos dados e permite auditorias (time travel), fundamentais para conformidade com a LGPD em processos de seguros.
Processamento e ML	AWS Glue ETL vs. Databricks (Spark/MLflow)	O Glue possui interface limitada para ciência de dados. O Databricks oferece notebooks colaborativos e gestão de ciclo de vida de modelos (MLflow).	Escolha Estratégica: O Databricks permite a portabilidade total das regras de negócio e ML. Devido à complexidade e importância do Score de Risco e outras análises para sinistros e fraudes, o código pode ser movido para outra nuvem sem reescrita.
Governança	Lake Formation vs. Unity Catalog	O Lake Formation é exclusivo AWS. O Unity Catalog gerencia permissões, linhagem e metadados de forma centralizada e agnóstica.	Facilita a gestão de dados em ambientes híbridos ou multi-cloud. O Unity Catalog foi escolhido por permitir funcionalidades avançadas para dados e IA (como a linhagem de dados) de forma nativa no Databricks, garantindo que a governança seja portátil para qualquer nuvem.
Segurança (Acesso e Criptografia)	AWS IAM	Gerenciamento de identidade e acesso para definir quem pode ler/escrever nos buckets.	Essencial para garantir que apenas as aplicações, cluster do Databricks e usuários autorizados acessem dados sensíveis de seguros.
	AWS KMS	Serviço de gerenciamento de chaves para criptografia de dados em repouso e em trânsito.	Garante a conformidade com a LGPD , protegendo os dados de apólices contra acessos não autorizados a nível de disco.
Visualização	Amazon QuickSight	Ferramenta de BI <i>Serverless</i> que se conecta diretamente às camadas de dados para criar dashboards executivos.	Mantida como solução nativa por sua excelente integração de custo-benefício (OpEx) e facilidade de escala conforme o número de usuários cresce.

Arquitetura Cloud AWS + Databricks Delta Lake (Lakehouse) | Seguradora - Machine Learning (Score de Risco) + BI



4.1 Resumo da Arquitetura

O diagrama técnico apresenta uma solução de Data Lakehouse ponta a ponta, estruturada para garantir escalabilidade e portabilidade. O fluxo divide-se em quatro macroetapas:

- **Ingestão de Dados:** O Amazon Kinesis captura fluxos contínuos de diversas fontes (aplicações, bancos relacionais e telemetria).
- **Armazenamento e Governança:** Centralização no Amazon S3 (formato Delta Lake). A governança é gerida pelo Databricks Unity Catalog e a segurança pelo AWS KMS, garantindo conformidade com a LGPD.
- **Processamento (Arquitetura Medalhão):** A gestão de acessos e identidades é controlada pelo AWS IAM, e garante que o Databricks tenha permissões granulares para organizar o refinamento dos dados. Esta estrutura única suporta simultaneamente diversas frentes de negócio:
 - Ciência de Dados: Modelos de Machine Learning para Score de Risco e Detecção de Fraudes em sinistros.
 - Gestão de Produtos: Análise de performance de apólices e comportamento do consumidor.
 - Gestão Financeira: Consolidação de pagamentos, prêmios e análises de rentabilidade a partir da camada Gold.
- **Visualização (Analytics e BI):** O Amazon QuickSight consome os dados refinados para gerar dashboards que atendem desde o nível operacional até o executivo.

4. Conclusão

A implementação de Data Lakehouse utilizando AWS e Databricks possibilita um alto grau de maturidade analítica e competitividade. A arquitetura proposta não apenas resolve o desafio técnico de processar e integrar grandes volumes de dados (estruturados, semiestruturados e não estruturados), mas também entrega três pilares fundamentais para o negócio:

- **Agilidade e Versatilidade:** através da Arquitetura Medalhão, uma única infraestrutura é capaz de democratizar o acesso aos dados, permitindo que Engenheiros, Cientistas, Analistas de Dados, MLOps e entre outras funções, colaborem na mesma "versão dos dados". Isso agiliza os processos, desde o cálculo de Score de Risco e Detecção de Fraudes até relatórios complexos de Gestão Financeira e de Produtos.
- **Eficiência Financeira (OpEx):** ao adotar serviços gerenciados e *serverless*, as empresas migram de um modelo de custos fixos (CapEx) para um modelo de pagamento por uso (OpEx). A escalabilidade automática garante que a infraestrutura acompanhe o crescimento da demanda sem desperdício de recursos.
- **Governança:** o uso do Unity Catalog em conjunto com AWS IAM e KMS garante uma governança robusta e conformidade com a LGPD.

- **Portabilidade:** ao utilizar o padrão Delta Lake, Databricks e Unity Catalog, a solução permanece agnóstica, mitigando o risco de *vendor lock-in* (dependência tecnológica de um único fornecedor) de ferramentas nativas das clouds, e permitindo uma futura estratégia multi-cloud e maior facilidade para migração das regras de negócio e Machine Learning, considerando esse último ponto como de grande relevância ao se considerar o desenho de uma arquitetura para gestão de dados, pois trata-se do core do negócio.

Em suma, o projeto entrega uma base sólida, segura e altamente flexível, preparada para transformar dados brutos em inteligência de negócio e decisões estratégicas em tempo real.