

Arquiteturas de Dados e Inteligência Artificial com Databricks e Snowflake

MBA Data Science & Advanced Analytics | Scalable Big Data Architecture | Turma: DSA_32 | RA: 2600190 | Lilian Reis

1. Objetivo

1. Contexto e Objetivo: Este trabalho tem como objetivo planejar duas arquiteturas de dados e inteligência artificial, uma baseada na plataforma Databricks e outra baseada na plataforma Snowflake, considerando o mesmo contexto de negócio, requisitos funcionais e não funcionais.

Ao final do trabalho, os grupos envolvidos deverão recomendar qual delas se mostra, não apenas do ponto de vista tecnológico, mas principalmente com base na relação de itens do escopo do trabalho. O foco principal não é apenas identificar “qual plataforma é melhor”, mas, considerando objetivos atuais e futuros da organização.

2. Escopo do Trabalho: Cada grupo deverá desenvolver uma proposta arquitetural completa, contemplando os seguintes aspectos:

2.1 Arquitetura de Dados

- Ingestão de dados (batch e streaming)
- Integração com fontes de dados diversas (estruturadas, semi-estruturadas e não estruturadas)
- Camadas de armazenamento e processamento
- Estratégia de transformação e modelagem de dados
- Governança, qualidade e catalogação de dados
- Segurança, controle de acesso e compliance

2.2 Arquitetura de Inteligência Artificial e Analytics

- Suporte a analytics descritivo, diagnóstico, preditivo e prescritivo
- Arquitetura para Machine Learning e/ou GenAI
- Ciclo de vida de modelos (treinamento, versionamento, deploy e monitoramento)
- Integração com ferramentas de BI e consumo analítico
- Escalabilidade e performance para workloads de dados e IA

2.3 Arquitetura Técnica e Operacional

- Componentes principais da plataforma
- Integração com o ecossistema cloud existente
- Estratégia de escalabilidade e elasticidade
- Operação, monitoramento e observabilidade
- Custos, modelo de consumo e eficiência operacional

3. Premissas:

- O cenário de negócio, requisitos e dados de entrada serão os mesmos para ambas as propostas.
- As arquiteturas devem refletir as características de cada plataforma.
- Não é esperado um nível de detalhamento de implementação, mas sim a análise e planejamento estratégico.
- As propostas devem considerar não apenas o estado atual, mas também escalabilidade para o futuro.

4. Critérios de Avaliação e Comparação: Após a elaboração das duas arquiteturas, os grupos deverão realizar uma análise comparativa, abordando de forma explícita:

- Adequação da arquitetura aos objetivos de negócio
- Flexibilidade e capacidade de evolução
- Suporte a casos de uso avançados de dados e IA
- Simplicidade versus complexidade operacional
- Governança, segurança e compliance
- Eficiência de custos e modelo de consumo
- Aderência ao contexto organizacional e maturidade da empresa

5. Resultado Esperado: Como resultado final, espera-se:

- Duas propostas arquiteturais bem estruturadas:
- Arquitetura baseada em Databricks

- Arquitetura baseada em Snowflake
- Uma recomendação da solução considerada mais indicada
- Argumentação técnica e estratégica sólida, demonstrando entendimento profundo:
 - Do problema de negócio
 - Das capacidades e limitações de cada plataforma
 - Dos impactos de longo prazo da decisão arquitetural

2. Cenário de Negócio: Seguradora Digital de Alta Escala

O setor de seguros é altamente competitivo e orientado por dados, exigindo agilidade na análise de informações, precisão na precificação de produtos e eficiência na gestão de sinistros. A organização em estudo lida com um ecossistema de dados complexo que demanda uma arquitetura de Big Data robusta:

- **Volume e Variedade:** Processamento de grandes volumes de dados **estruturados** (apólices, sinistros históricos em SQL), **semiestruturados** (telemetria de veículos via dispositivos IoT e logs de aplicativos em JSON) e **não estruturados** (fotos de vistorias, vídeos de acidentes e documentos digitalizados).
- **Velocidade e Tempo Real:** Necessidade de ingestão em fluxo contínuo (*streaming*) para detecção de fraudes no momento do aviso de sinistro e cálculo de score de risco instantâneo para novos clientes.
- **Inteligência Artificial:** Capacidade de escalar modelos de Machine Learning para milhares de inferências simultâneas, garantindo que o **Score de Risco** e a **Detecção de Fraude** operem com alta performance.
- **Governança e Compliance:** Rigorosa aderência à **LGPD**, exigindo rastreabilidade com data lineage (linhagem de dados), mascaramento de informações sensíveis e auditoria completa de quem acessa cada dado.
- **Eficiência Operacional (OpEx):** Transição de um modelo de custo fixo para um modelo de pagamento por uso, garantindo que a infraestrutura acompanhe picos de demanda (como em grandes eventos climáticos que geram massa de sinistros) sem desperdício de recursos.

Nesse contexto, este trabalho avalia duas plataformas líderes, **Databricks** e a **Snowflake**, para determinar qual delas melhor suporta o crescimento exponencial dos dados e a democratização da IA na companhia.

3. Arquitetura de Dados

Para atender ao cenário da seguradora, foram desenhadas duas soluções que garantem escalabilidade para Big Data e suporte avançado para IA. Ambas as arquiteturas seguem o modelo de separação entre armazenamento e computação, permitindo elasticidade conforme a demanda de processamento de sinistros e cálculos de score.

Comparativo de Arquitetura de Dados

A tabela abaixo detalha como cada plataforma gerencia as etapas do ciclo de vida dos dados:

Etapa		Databricks (Lakehouse)	Snowflake (Data Cloud)	Racional de Escolha
Ingestão (Batch/Stream)		Auto Loader & Spark Streaming: Ingestão de telemetria e arquivos.	Snowpipe: Ingestão automatizada de arquivos no S3.	Databricks leva vantagem em telemetria complexa (IoT) e tempo real.
Variedade de Dados		Suporte nativo para fotos/vídeos e dados estruturados.	Foco em estruturados. Fotos via <i>Directory Tables</i> .	Databricks é superior para vistorias (fotos) devido ao motor Spark.
Armazenamento		Delta Lake (S3): Formato aberto (Open Source) e ACID.	Micro-partições: Formato fechado e proprietário.	Databricks evita o <i>Vendor Lock-in</i> por usar padrões abertos.
Transformação		Delta Live Tables (DLT): Pipelines em SQL e Python.	Dynamic Tables: Transformações contínuas em SQL.	Snowflake é mais simples (SQL); Databricks é mais flexível (Python).
Governança		Unity Catalog: Centralizado para arquivos e IA.	Snowflake Horizon: Focado em privacidade e BI.	Databricks integra Governança de Dados com IA de forma mais nativa.
Escalabilidade		Cluster Spark (Horizontal/Vertical).	Virtual Warehouses (Separação total).	Snowflake escala mais rápido para BI; Databricks escala melhor para IA.

Databricks: A estratégia de transformação utiliza a **Arquitetura Medalhão**. Os dados brutos de sinistros e telemetria entram na camada **Bronze**. Na camada **Silver**, o Spark realiza a limpeza e padronização, permitindo que as fotos das vistorias sejam processadas por algoritmos de visão computacional. Na camada **Gold**, os dados são agregados para o cálculo final do Score de Risco, garantindo alta performance para o consumo de BI.

Snowflake: A abordagem foca na **Simplicidade Operacional**. Os dados são ingeridos via Snowpipe para tabelas de *staging*. Através do uso de **Virtual Warehouses** (clusters de computação elásticos), o Snowflake escala instantaneamente para processar grandes volumes de dados de apólices, permitindo que o time de negócios execute consultas complexas sem impactar o desempenho da ingestão.

4. Arquitetura de Inteligência Artificial e Analytics

Nesta camada, o objetivo é transformar os dados refinados em decisões inteligentes. Para a seguradora, isso significa prever o risco de um novo cliente (score) e identificar comportamentos suspeitos em sinistros (fraude) de forma escalável.

Comparativo de IA e Ciclo de Vida de Modelos (MLOps)

Etapa do Ciclo de ML	Databricks (Spark + MLflow)	Snowflake (Snowpark + Cortex)	Racional de Escolha
Análise Exploratória (EDA)	Notebooks colaborativos com Spark (Python/R/SQL) para volumes massivos.	Notebooks integrados e suporte a Python via Snowpark.	Databricks é mais maduro para exploração de grandes volumes de dados brutos.
Treinamento do Modelo	AutoML e treinamento distribuído com Spark MLlib e GPUs.	Snowpark ML: Treinamento de modelos Scikit-learn/XGBoost dentro do Snowflake.	Databricks escala melhor para modelos complexos de Deep Learning (fotos de vistorias).
Versionamento e Tracking	MLflow Tracking: Registro automático de parâmetros, métricas e código.	Snowflake Model Registry: Gestão de versões de modelos dentro do catálogo.	MLflow é o padrão de mercado e oferece maior detalhamento para Auditoria/Compliance.
Deploy e Inferência	Model Serving: Publicação de modelos como APIs de baixa latência (Serverless).	UDFs (User Defined Functions): Modelos correm como funções dentro do SQL.	Snowflake é excelente para previsões em tabelas; Databricks para APIs em tempo real.
Monitoramento	Monitoramento nativo de <i>drift</i> de dados e performance do modelo.	Monitoramento via tabelas de observabilidade e alertas.	Ambos atendem, mas o Databricks integra melhor com o ciclo de vida completo de ML.

No **Databricks** (foco em **Profundidade Técnica**): A arquitetura utiliza o **MLflow** como espinha dorsal. Desde a fase de experimentação até o deploy, todas as ações são registradas no **Unity Catalog**. Para o caso de **Deteção de Fraude em Fotos**, o Databricks utiliza clusters com GPU para processar redes neuronais, garantindo que a análise de uma imagem de sinistro seja feita em milissegundos. A escalabilidade é garantida pelo motor Spark, que distribui o treino do modelo de Score de Risco por múltiplos nós.

Além do suporte a modelos preditivos com MLflow, a plataforma Databricks está preparada para o futuro com a **IA Generativa**. Através de aquisições como a MosaicML e parcerias com as principais nuvens, a seguradora poderia, por exemplo, utilizar modelos foundation para **sumarizar automaticamente laudos de sinistros** ou criar um **chatbot** para atendimento ao cliente, treinado com base nas apólices e no histórico da empresa, tudo isso com a governança e escalabilidade do Lakehouse.

No **Snowflake** (foco em **Simplicidade e Dados Estruturados**): A abordagem utiliza o **Snowpark**, que permite que os cientistas de dados escrevam código Python que é executado diretamente nos *Virtual Warehouses* do Snowflake. Isto elimina a necessidade de mover dados para fora da plataforma (segurança). Para o **Score de Risco**, o Snowflake é extremamente eficiente, pois consegue aplicar o modelo em milhões de linhas de clientes utilizando a linguagem SQL que o time de negócio já domina, facilitando a integração com ferramentas de BI.

O Snowflake Cortex, camada de IA totalmente gerenciada, permite que a seguradora incorpore capacidades de IA generativa de forma simples e segura. Através de funções SQL nativas, seria possível **analisar o sentimento de reclamações de clientes** em canais de texto ou **extrair informações-chave de documentos digitalizados** (como boletins de ocorrência), democratizando o acesso à IA para toda a equipe de negócios, sem a necessidade de gerenciar infraestrutura complexa.

Um aspecto crítico do ciclo de vida de ML é o monitoramento pós-deploy. No **Databricks**, o MLflow oferece capacidades nativas para detectar *data drift* (mudanças nos dados de entrada) e *concept drift* (perda de performance do modelo), podendo disparar alertas ou acionar um re-treinamento automático. Já no **Snowflake**, o monitoramento é feito através de tabelas de observabilidade e alertas, que podem ser configurados para rastrear as métricas de performance das previsões ao longo do tempo, garantindo que o modelo de Score de Risco mantenha sua acurácia

5. Arquitetura Técnica e Operacional

Este tópico descreve a base tecnológica que sustenta as operações de dados e IA, com foco em como as plataformas se integram ao ecossistema de nuvem e como gerenciam o crescimento da demanda de forma eficiente.

Comparativo de Infraestrutura e Eficiência Operacional

Requisito Técnico	Databricks (Lakehouse)	Snowflake (Data Cloud)	Racional de Escolha
Componentes Principais	Clusters Spark (Control & Data Plane), Unity Catalog e Serverless SQL.	Virtual Warehouses, Global Services e Storage Layer.	Snowflake é mais "caixa fechada" (SaaS); Databricks oferece mais controle técnico.
Integração Cloud	Integração profunda com S3, IAM e KMS via redes privadas (VPC Peering).	Executa sobre a infraestrutura cloud, mas gerencia o storage de forma abstraída.	Databricks facilita a estratégia Multi-Cloud por usar formatos abertos (Delta).
Escalabilidade	Escalabilidade horizontal de nós (Workers) e instâncias Spot para economia.	Escalabilidade instantânea de Warehouses (T-shirt sizes: XS, S, M, L).	Snowflake escala mais rápido para picos de BI; Databricks é mais eficiente para Jobs longos.
Observabilidade	Monitoramento via Ganglia, logs de auditoria e integração com CloudWatch.	Query Profile, histórico de uso de créditos e ferramentas de auditoria nativas.	Snowflake simplifica a visão de custos; Databricks detalha melhor a performance do código.
Modelo de Consumo	Baseado em DBUs (Databricks Units) + custo de infraestrutura da Cloud.	Baseado em Créditos Snowflake (inclui processamento e storage gerenciado).	Databricks costuma ser mais econômico para grandes volumes de processamento (ETL).

- **Escalabilidade e Elasticidade:** No **Databricks**, a escalabilidade é orientada à carga de trabalho (workload). Para o processamento de grandes lotes de sinistros, o cluster pode aumentar o número de máquinas automaticamente (*Auto-scaling*). No **Snowflake**, a elasticidade é quase instantânea; se houver um pico de acessos simultâneos de diretores consultando painéis de fraude, a plataforma escala o *Virtual Warehouse* para garantir que ninguém sofra com lentidão.

- **Integração e Custos (OpEx):** O **Databricks** integra-se de forma nativa com os serviços de segurança e armazenamento das principais clouds (AWS, Azure, GCP), permitindo que os dados permaneçam no ambiente do cliente. O **Snowflake** centraliza o gerenciamento, o que reduz o custo de mão de obra operacional (menos pessoas para configurar a infra), mas pode gerar um custo de créditos mais elevado se não for monitorado de perto. Ambas as soluções seguem o modelo **OpEx** (pagamento por uso), mas com filosofias distintas, o que é ideal para a seguradora.

O **Databricks** cobra por DBUs (Databricks Units) com base na computação provisionada, mesmo que o cluster esteja ocioso (embora com auto-scaling e suporte a instâncias Spot para redução de custos). Isso oferece previsibilidade para workloads contínuos, como os pipelines de ETL da camada medalhão. O **Snowflake**, por outro lado, cobra apenas pelo tempo de processamento efetivo dos *Virtual Warehouses* (por segundo). Este modelo é extremamente eficiente para cargas de trabalho intermitentes e imprevisíveis, como as consultas analíticas dos diretores durante um pico de sinistros.

A escolha, portanto, envolve um trade-off: o Databricks tende a ser mais econômico para **processamento pesado e contínuo** de big data, enquanto o Snowflake leva vantagem na **elasticidade para BI e cargas variáveis**.

6. Arquitetura Ponta a Ponta

Tabela Resumo: Esta tabela consolida todos os componentes discutidos, servindo como mapa mestre para a comparação final.

Camada / Requisito	Databricks (Lakehouse)	Snowflake (Data Cloud)	Racional de Escolha (Vantagem)
Ingestão	Auto Loader / Spark Streaming	Snowpipe / COPY INTO	Databricks é superior para telemetria (IoT) e imagens.
Armazenamento	Delta Lake (S3 - Formato Aberto)	Tabelas Proprietárias (Micro-partições)	Databricks evita <i>Vendor Lock-in</i> .
Processamento	Clusters Spark Dinâmicos	Virtual Warehouses (T-Shirt Sizes)	Snowflake é mais simples; Databricks é mais potente para IA.
Arquitetura	Medalhão (Bronze, Silver, Gold)	Esquemas de Dados (Raw, Int, Analytics)	Ambos garantem qualidade e linhagem.
IA e Analytics	MLflow + Databricks SQL	Snowpark + Cortex	Databricks é o líder para Ciência de Dados avançada.
Governança	Unity Catalog	Snowflake Horizon	Databricks integra dados e modelos no mesmo catálogo.
Escalabilidade	Horizontal (Auto-scaling de Workers)	Vertical/Horizontal (Multi-cluster)	Snowflake escala rápido para BI; Databricks para Big Data.

Arquitetura de Dados e Governança:

Em termos de **LGPD**, ambas as plataformas oferecem mecanismos robustos. O **Unity Catalog (Databricks)** permite a criação de **Dynamic Views**, onde colunas com dados sensíveis (como CPF ou dados médicos do segurado) são mascaradas dinamicamente com base no papel do usuário que realiza a consulta.

Da mesma forma, o **Snowflake Horizon** oferece **Dynamic Data Masking e Row-Level Security**, permitindo que políticas de segurança sejam aplicadas diretamente nas tabelas via SQL, garantindo que um corretor, por exemplo, veja apenas os dados dos seus próprios clientes.

7. Arquitetura Proposta – Justificativa

Após a análise detalhada de ambas as plataformas sob a ótica de **Escalabilidade e Big Data**, a solução recomendada para a seguradora é o **Databricks**.


Justificativa Estratégica baseada nos itens de escopo:

- **Suporte a Casos de Uso Avançados (IA e Imagens):** O diferencial competitivo da seguradora reside na detecção de fraude via fotos de sinistros e no Score de Risco baseado em telemetria. O Databricks, através do motor Spark, processa dados não estruturados nativamente, algo que o Snowflake ainda trata de forma limitada.
- **Flexibilidade e Evolução (Lock-in):** Ao utilizar o formato **Delta Lake**, a seguradora mantém a propriedade dos dados em um formato aberto, permitindo evoluir a arquitetura sem ficar "presa" a um único fornecedor, facilitando migrações e estratégia multi-cloud.
- **Ciclo de Vida de ML (MLOps):** O uso do **MLflow** integrado ao **Unity Catalog** oferece uma governança superior para modelos preditivos, garantindo que o Score de Risco seja auditável e escalável.
- **Eficiência de Custos em Big Data:** Para processamento de grandes volumes (Engenharia de Dados pesada), o Databricks apresenta um TCO (Custo Total de Propriedade) mais eficiente ao permitir o uso de instâncias Spot e maior controle sobre a computação.
- **Analytics Integrado e Visão 360° do Cliente:** Para além dos benefícios técnicos, a plataforma Databricks possibilita uma **jornada analítica completa e unificada** dentro do mesmo ambiente. A seguradora poderá evoluir do diagnóstico de sinistros (analytics descritivo e diagnóstico) para a prescrição de ações preventivas baseadas em modelos preditivos, tudo isso com a mesma governança e sem movimentação desnecessária de dados entre sistemas. Essa integração reduz a complexidade operacional e acelera o time-to-insight, permitindo que a organização não apenas reaja a eventos, mas antecipe riscos e personalize ofertas de forma ágil. Além disso, a capacidade de combinar, em um mesmo pipeline, dados estruturados de apólices com imagens de vistorias e streams de telemetria viabiliza uma **visão 360° do cliente e do sinistro**, criando uma base sólida para iniciativas de marketing personalizado, prevenção de perdas e melhoria contínua da experiência do segurado, um diferencial competitivo essencial no mercado de seguros.

Arquitetura de Dados para Seguradora com Databricks:

Abaixo segue o diagrama de um exemplo de Arquitetura com Databricks para Seguradora.

Arquitetura Cloud AWS + Databricks Delta Lake (Lakehouse) | Seguradora - Machine Learning (Score de Risco) + BI



Resumo do Diagrama: Exemplo de Arquitetura AWS Delta Lake + Databricks

O diagrama acima apresenta uma solução de Data Lakehouse ponta a ponta, estruturada para garantir escalabilidade e portabilidade. O fluxo divide-se em quatro macroetapas:

- **Ingestão de Dados:** O Amazon Kinesis captura fluxos contínuos de diversas fontes (aplicações, bancos relacionais e telemetria).
- **Armazenamento e Governança:** Centralização no Amazon S3 (formato Delta Lake). A governança é gerida pelo Databricks Unity Catalog e a segurança pelo AWS KMS, garantindo conformidade com a LGPD.
- **Processamento** (Arquitetura Medalhão): A gestão de acessos e identidades é controlada pelo AWS IAM, e garante que o Databricks tenha permissões granulares para organizar o refinamento dos dados. Esta estrutura única suporta simultaneamente diversas frentes de negócio:
 - **Ciência de Dados:** Modelos de Machine Learning para Score de Risco e Detecção de Fraudes em sinistros.
 - **Gestão de Produtos:** Análise de performance de apólices e comportamento do consumidor.
 - **Gestão Financeira:** Consolidação de pagamentos, prêmios e análises de rentabilidade a partir da camada Gold.
- **Visualização (Analytics e BI):** O Amazon QuickSight ou Power BI, consome os dados refinados para gerar dashboards que atendem desde o nível operacional até o executivo.

8. Conclusão

A análise detalhada e comparação entre **Databricks** e **Snowflake** demonstrou que, embora ambas as plataformas ofereçam excelência em escalabilidade, elasticidade e modelo de consumo OpEx, elas possuem especializações distintas. A avaliação final, baseada nos critérios propostos, revela:

- **Adequação aos objetivos de negócio:** Ambas atendem, mas o **Databricks** se alinha melhor ao objetivo estratégico de inovar com IA sobre dados não estruturados (fotos e telemetria).
- **Flexibilidade e capacidade de evolução:** O **Databricks** é superior devido ao formato aberto **Delta Lake**, que previne o *vendor lock-in* e garante a soberania dos dados, um fator crucial para a estratégia de longo prazo.
- **Suporte a casos de uso avançados de dados e IA:** Novamente, o **Databricks** lidera com o processamento nativo de imagens (visão computacional) e o ecossistema MLflow para um ciclo de vida de MLOps completo e auditável.
- **Simplicidade versus complexidade operacional:** O **Snowflake** ganha em simplicidade, especialmente para equipes que dominam SQL e workloads de BI. O **Databricks**, embora mais complexo, oferece a flexibilidade necessária para os times de dados da seguradora.
- **Governança, segurança e compliance:** Ambos são excelentes (Unity Catalog e Snowflake Horizon). O diferencial do **Databricks** é unificar a governança de **dados e modelos de IA** no mesmo catálogo, simplificando a auditoria de todo o ciclo de vida, um requisito crítico para a LGPD.

- **Eficiência de custos:** Para os workloads de Big Data da seguradora (processamento contínuo de telemetria e imagens), o modelo de custo do **Databricks** com instâncias Spot tende a ser mais econômico e previsível.
- **Aderência ao contexto organizacional:** Considerando a maturidade necessária para implementar projetos de visão computacional e a ambição de se tornar uma seguradora data-driven, a plataforma **Databricks** oferece um ecossistema mais completo para a jornada de IA.

Portanto, considerando o ecossistema complexo da seguradora, que exige o processamento de **dados não estruturados (vistorias por foto)**, telemetria IoT em tempo real e um ciclo de vida de Machine Learning rigoroso, a plataforma **Databricks** revela-se a solução mais indicada. A escolha pelo Databricks justifica-se por sua capacidade de inovação, governança unificada e soberania dos dados, estabelecendo uma base tecnológica elástica e resiliente para o futuro.